

Classificador para a distinção entre mosquitos transmissores de doenças utilizando IA.

Nomes: João Paulo de Souza

Raul Moreno Pereira

Matrículas: 968, 973

Abril de 2025

Introdução e Motivação

As arboviroses transmitidas por mosquitos, como dengue, zika e chikungunya, representam um grave problema de saúde pública em diversas regiões do mundo, especialmente em países tropicais como o Brasil. Entre os principais vetores dessas doenças estão os mosquitos *Aedes aegypti* e *Aedes albopictus*, espécies morfológicamente semelhantes, mas com diferenças significativas em seu comportamento, ecologia e importância epidemiológica.[1] O *Aedes aegypti* é amplamente reconhecido como o principal vetor da dengue no Brasil, devido à sua elevada adaptação ao ambiente urbano e à sua forte associação com a espécie humana. [2] Por outro lado, embora o *Aedes albopictus* seja competente para transmitir o vírus da dengue em condições laboratoriais, ele não é considerado atualmente um vetor significativo da doença no país, sendo mais comum em ambientes rurais e periurbanos. [3]

A diferenciação entre *A. aegypti* e *A. albopictus* é tradicionalmente feita por meio da análise morfológica por especialistas treinados, um processo que pode ser demorado, sujeito a erros e dificultado pela condição dos espécimes coletados. [4] Nesse contexto, o uso de inteligência artificial (IA), especialmente por meio de técnicas de visão computacional e aprendizado de máquina, surge como uma alternativa promissora. Essas tecnologias permitem automatizar a classificação de mosquitos com alta acurácia e viabilizar análises em larga escala e em tempo real. [5]

Conceitos

A inteligência artificial (IA) é um campo da ciência da computação voltado ao desenvolvimento de sistemas capazes de executar tarefas que normalmente requerem inteligência humana, como reconhecimento de padrões, tomada de decisão e aprendizado com dados [6]. Um dos ramos mais dinâmicos da IA é o aprendizado de máquina (*machine learning*), que permite que algoritmos aprendam padrões a partir de conjuntos de dados, sem necessidade de programação explícita para cada caso específico. No contexto do presente projeto, a técnica mais relevante é o aprendizado supervisionado, onde o algoritmo é treinado com exemplos rotulados para que aprenda a classificá-los corretamente em novos casos [7].

Aliada à IA, a visão computacional é a área responsável por permitir que sistemas digitais “enxerguem” e interpretem informações visuais, como imagens ou vídeos. Essa tecnologia permite extrair, processar e analisar características visuais relevantes dos dados, como forma, textura, cor ou padrões específicos das asas e corpo dos mosquitos [8]. Para o caso específico da classificação de mosquitos vetores, o uso combinado de IA e visão computacional permite não apenas automatizar a identificação das espécies com alta acurácia, mas também lidar com grandes volumes de dados visuais gerados por armadilhas entomológicas ou sistemas de vigilância digital.

Problema a ser resolvido

Apesar das diferenças entre o *Aedes aegypti* e *Aedes albopictus*, ambas as espécies são morfologicamente muito semelhantes, o que torna sua distinção visual um desafio técnico, especialmente quando realizada por profissionais com pouca experiência ou em condições de campo adversas. A dificuldade em diferenciar essas espécies com precisão pode comprometer estratégias de vigilância e controle, resultando em alocação inadequada de recursos e subestimação do risco em determinadas áreas.




Figura 1: *Aedes aegypti* e *Aedes albopictus* [10].

Hipótese para a resolução do Problema

Neste contexto, soluções baseadas em visão computacional podem se tornar alternativas promissoras. Técnicas modernas, como as redes neurais convolucionais (CNNs), são capazes de aprender características visuais relevantes — como textura e padrões corporais dos mosquitos — mesmo em condições de variação de pose, iluminação ou resolução [9]. A aplicação dessas tecnologias permite maior padronização, agilidade e escalabilidade na identificação entomológica, contribuindo diretamente para o fortalecimento da resposta das autoridades de saúde pública frente às arboviroses.

Entretanto, para que o modelo seja bem sucedido, é necessário uma boa base de dados para que seja feito um treinamento eficiente. Caso a base de dados seja insuficiente, pode levar a overfitting (modelo aprende o conjunto de treino, mas falha em dados reais) e dificuldade em transferir os modelos para diferentes contextos geográficos ou ambientais[5].

Treinando um modelo de Inteligência Artificial que usa dados morfológicos de diferentes espécies de mosquitos para filtrar características relevantes e identificar o *Aedes Aegypti*, reconhecendo padrões característicos da espécie, o modelo poderá diferenciá-lo de espécies semelhantes, podendo usar a aplicação em dispositivos embarcados diretamente em campo.

Descrição da abordagem

O projeto será conduzido em etapas, iniciando com o pré processamento de dados relevantes de diferentes espécies de mosquitos. Com o objetivo de obter uma base de dados ampla que destaque características importantes como tamanho do corpo, padrão das asas, coloração, entre outros atributos biológicos extraídos de imagens do inseto. Após definida a base que destaca atributos mais relevantes para a diferenciação da espécie transmissora da dengue, será desenvolvido e treinado um modelo de classificação utilizando técnicas de Machine Learning supervisionado.




Figura 2: Exemplo de modelo classificador.

Ao construir o modelo, seu desempenho será avaliado, usando o erro quadrático médio como métrica. Ao comprovar sua capacidade preditiva, ele será convertido para o formato compatível com TinyML, utilizando a ferramenta TFlite, garantindo a viabilidade do modelo em dispositivos com recursos limitados, como smartphones. O modelo final será testado usando de smartphones para captar novas imagens que possam ser lidas pelo modelo, para analisar a sua precisão de acordo com a predição.

A rede LSTM proposta inicialmente neste trabalho possui uma camada oculta composta por 32 a 512 neurônios, ajustados pela biblioteca *Keras Turner*, utilizando a função de ativação ReLU. Após a camada LSTM, existe uma camada de dropout otimizada, com uma taxa de 0,3. A camada de entrada possui 20 neurônios e recebe sequências com 10 *timesteps* e 20 características (posição dos dispositivos IoT), enquanto a camada de saída possui 2 neurônios.

Conclusão e Contribuições Esperadas

A proposta do projeto é oferecer uma solução prática e portátil para identificar o *Aedes aegypti*, auxiliando no monitoramento e combate à dengue. A

aplicação de IA aliada ao TinyML permite que essa tecnologia seja acessível e utilizável em dispositivos móveis, inclusive em lugares com infraestrutura limitada. Ao final do projeto, espera-se obter uma ferramenta funcional, com alta precisão de classificação, podendo ser integrada às estratégias brasileiras de controle de vetores epidemiológicos.

Referências

1. Kraemer, M. U. G. (2015). "*The global distribution of the arbovirus vectors Aedes aegypti and Ae. albopictus*". Em: eLife, 4, e08347. DOI:<https://doi.org/10.7554/eLife.08347>
2. Couto-Lima, D., Madec, Y., Bersot, M.I. et al. "*Potential risk of re-emergence of urban transmission of Yellow Fever virus in Brazil facilitated by competent Aedes populations*."Em: Sci Rep 7, 4848 (2017). DOI: <https://doi.org/10.1038/s41598-017-05186-3>
3. BRAGA, I. A., VALLE, D. "*Aedes aegypti: histórico do controle no Brasil*."Em: Epidemiol. Serv. Saúde [online]. 2007, vol.16, n.2, pp.113-118. DOI: <http://dx.doi.org/10.5123/S1679-49742007000200006>.
4. Devi Shankar Suman, Anchal R. Shrivastava, S.C. Pant, Brahma Dutta Parashar. "*Differentiation of Aedes aegypti and Aedes albopictus (Diptera: Culicidae) with egg surface morphology and morphometrics using scanning electron microscopy*"Em: Arthropod Structure Development, Volume 40, Issue 5, 2011, Pages 479-483, ISSN 1467-8039. DOI: <https://doi.org/10.1016/j.asd.2011.04.003>.
5. Ananya Joshi, Clayton Miller. "*Review of machine learning techniques for mosquito control in urban environments*", Em: Ecological Informatics, Volume 61, 2021, 101241, ISSN 1574-9541, DOI: <https://doi.org/10.1016/j.ecoinf.2021.101241>.
6. Russell, S. J., Norvig, P. (2021). "*Artificial Intelligence: A Modern Approach*"(4th ed.). Pearson. DOI: <https://doi.org/10.1109/MSP.2017.2765202>
7. Goodfellow, I., Bengio, Y., Courville, A. (2016). "*Deep Learning*". Em: MIT Press. Disponível em: <http://www.deeplearningbook.org>

8. Szeliski, R. (2022). "*Computer Vision: Algorithms and Applications*"(2nd ed.). Springer.
9. Goodwin, A., Padmanabhan, S., Hira, S. et al. "*Mosquito species identification using convolutional neural networks with a multitiered ensemble model for novel species detection.*"Em: Sci Rep 11, 13656 (2021). DOI: <https://doi.org/10.1038/s41598-021-92891-9>
10. Identificando o “Mosquito da Dengue” – Culex x Aedes aegypti x Aedes albopictus, 2016. Disponível em: <https://pragaseeventos.com.br/identificando-o-mosquito-da-dengue-culex-x-aedes-aegypti-x-aedes-albopictus/> Acesso em: 01 maio. 2025.